ДЗ 5 Обучение вызову функций с RL

Данные и оценка

Обучал Qwen3.5-2B на ToolACE. Разделил целые диалоги 90/10 с сидом 42. Для подходящих реплик ассистента взял историю как вход и вызовы как эталон. Имена инструментов заменил на tool_0 и далее. Отфильтровал ошибки разбора и входы длиннее 3072 токеновНаграда и обучение

| Часть ToolACE | Диалоги | Пропущено | Примеры | Без вызова | Один вызов | Несколько | Средняя длина |
|---|---|---|---|---|---|---|---|
| Train | 10 170 | 862 | 11 546 | 2763 | 5181 | 3602 | 821 |
| Validation | 1130 | 86 | 1242 | 266 | 555 | 421 | 805 |

Точная награда даёт 1 за совпадение вызовов с аргументами, иначе 0. Порядок не важен, повторы учитываются. Частичная даёт сигнал при неполном совпадении. Это 0,45 × F1 по именам и 0,45 × F1 по тройкам функция, аргумент и значение. Если в прогнозе для Рима пропустить число дней, награды равны 0 и 0,75. Непустой ответ без вызова получает 1, когда вызов не нужен. Сломанная разметка получает 0

- GRPO с точной наградой проверяет, хватает ли полного совпадения

- GRPO с частичной наградой проверяет пользу частичного совпадения

- Dr. GRPO с той же наградой убирает деление advantage на стандартное отклонение и нормирует loss на фиксированную длину

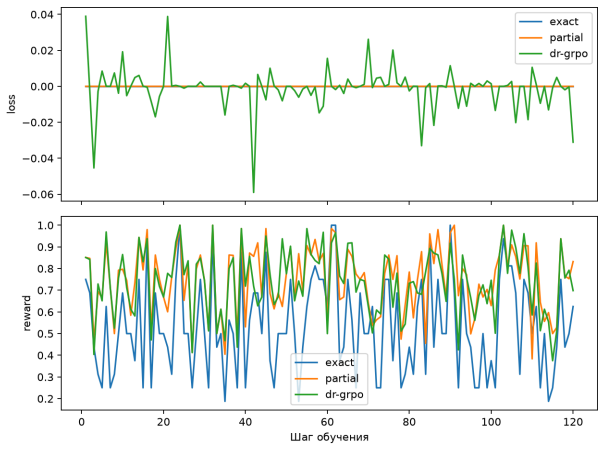
Везде LoRA с r 16 и alpha 32. LR 2e-5. Четыре ответа до 256 токенов, температура 0,8. Взял шаг 120. При одинаковой награде в группе advantage равен нулю

Результаты

BFCL на 350 примерах. Overall усредняет пять групп. Контроль без обучения

| Запуск | Overall | Simple | Multiple | Parallel | Parallel multiple | Irrelevance |
|---|---|---|---|---|---|---|
| Базовая модель | 68,93% | 68% | 78,70% | 56% | 80% | 62% |
| GRPO точная | 65,60% | 54% | 72% | 52% | 72% | 78% |
| GRPO частичная | 68,93% | 62% | 68,70% | 54% | 78% | 82% |
| Dr. GRPO | 71,60% | 70% | 80% | 56% | 82% | 70% |

Частичная награда дала наибольшую прибавку между соседними настройками при том же GRPO. Dr. GRPO с этой наградой дал лучший overall. На каждый вариант один запуск



У точного GRPO средняя награда выросла с 0,503 до 0,553 между первыми и последними 20 шагами, но BFCL снизился. Модель реже делала лишние вызовы и хуже справлялась с нужными

Ошибки Dr. GRPO

- irrelevance_233. Модель вызвала прогноз погоды вместо ответа про курс валют
- simple_241. Модель назвала Линкольна без вызова нужной функции
- parallel_105. Модель передала 350 K вместо 300 K в третьем вызове